

Procesamiento de Información Temporal
Tema 1:
Modelos Clásicos de Series Temporales
Parte 2: ARMA, (S)ARIMA(X),
Series Multivariadas

Alicia Lozano Díez

alicia.lozano@uam.es

Audias – Audio, Data Intelligence and Speech
Universidad Autónoma de Madrid

<http://audias.ii.uam.es>

Materiales basados en los de Daniel Ramos Castro

1

Contenidos: Tema 1 Parte 2

- Modelo MA y ARMA
- No estacionariedad: ARIMA y SARIMA
- Variables exógenas: SARIMAX
- Series multivariadas


2

Modelos Autorregresivos de Media Móvil (ARMA)

3

Modelo MA

- Modelo Moving Average (MA)
 - Modela una secuencia de errores (ruidos) pasados



$$\theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q \quad \tilde{z}_t = \theta(B) a_t$$

- Efecto de “suavizado” del error
- Si la serie presenta autocorrelación...
 - Es decir, “relación con sus propios valores pasados”
 - Entonces modelos MA poco adecuados
- Casi todas las series reales de interés son algo más que “ruido” a suavizar...

4

Modelo ARMA

- Modelo Autoregressive-Moving Average (ARMA)

- Combina linealmente modelos AR y MA

$$\tilde{z}_t = \phi_1 \tilde{z}_{t-1} + \dots + \phi_p \tilde{z}_{t-p} + a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}$$

$$\phi(B)\tilde{z}_t = \theta(B)a_t$$

[Box06]

- Doble efecto

- Es capaz de capturar relaciones de un punto con sus puntos anteriores (AR)
- Es capaz de suavizar el ruido blanco para que no influya tanto (MA)

- Adecuado para muchas series temporales “reales”

- ¡Ojo! Siempre **estacionarias**


- No tiene en cuenta posible no-estacionariedad

No Estacionariedad

No Estacionariedad

- Muchas series temporales reales pueden descomponerse en varias componentes

- Tendencia
- Estacionalidad
- Residuo




<https://machinelearningmastery.com/decompose-time-series-data-trend-seasonality/>

No Estacionariedad

- Residuo
 - Suele ser estacionaria **ARMA**

- Tendencia
 - Suele desaparecer **derivando/diferenciando**
 - En ocasiones varias veces **ARIMA**

- Estacionalidad
 - No desaparece derivando
 - Componente periódica
 - Derivada del seno = coseno...
 - Es necesario modelar esa parte por separado **SARIMA**



<https://machinelearningmastery.com/decompose-time-series-data-trend-seasonality/>

Modelo ARIMA

- Autorregresive **Integrative** Moving Average (ARIMA)
 - Primero derivamos hasta d veces
 - Objetivo: eliminar la influencia de la componente de tendencia

$$w_t = (1 - B)^d z_t = \nabla^d z_t \quad [\text{Box08}]$$

- Después, aplicar ARMA a dicho modelo derivado

$$w_t = \phi_1 w_{t-1} + \dots + \phi_p w_{t-p} + a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}$$

- Al realizar una predicción, se obtiene z_t como...


$$S w_t = \sum_{j=0}^{\infty} w_{t-j} = w_t + w_{t-1} + w_{t-2} + \dots \quad z_t = S^d w_t$$

$$S = \nabla^{-1} = (1 - B)^{-1}$$

- De dicha suma viene lo de "Integrative"

Modelo SARIMA

- **Seasonal** Autorregresive Integrative Moving Average (SARIMA)
 - Intenta estimar la componente estacional de la serie
 - Supone que dicha componente se suma o multiplica al resto
 - A la serie resultante le aplicamos ARIMA



Modelo SARIMA

- Suposición clave
 - La estacionariedad tiene periodo S (unidades temporales)
- Por ello, aplicamos un ARIMA que en lugar de tomar una unidad temporal toma S unidades temporales
 - Modelo de “estacionalidad” (diferenciación y oper. “backward” B de orden S)

$$\Phi(B^S)\nabla_S^D z_t = \Theta(B^S)\alpha_t$$

- Estrategia típica:
 - Suponer que dicha componente estacional es multiplicativa (más común)
 - La componente estacional “modula” la amplitud del resto de componentes de la serie
 - SARIMA multiplicativo: $\text{SARIMA}(p,d,q)\times(P,D,Q)_S$
 - Existen otras estrategias

Selección y Ajuste de Modelo Metodología Box-Jenkins

Metodología Box-Jenkins

- Cinco pasos clave

- Paso 1: postular clase general de modelos

- Se selecciona una familia de modelos

- Por ejemplo, modelos basados en filtros lineales...

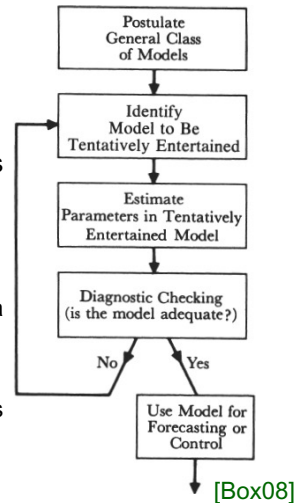
- Paso 2: identificar el modelo

- Función de autocorrelación (ACF)

- Correlación de una serie y ella misma desplazada

- Función de autocorrelación parcial (PACF)


- ACF eliminando la influencia de otros valores de desplazamiento




Metodología Box-Jenkins

- Ejemplo [Box08]


- "Serie A"



- ACF



- PACF




[Box08]


Metodología Box-Jenkins

■ Ejemplo [Box08]


□ "Serie C"



□ ACF



□ PACF



[Box08]

Metodología Box-Jenkins

■ Identificación del modelo (un método, hay variaciones)

□ Primero, identificar estacionariedad

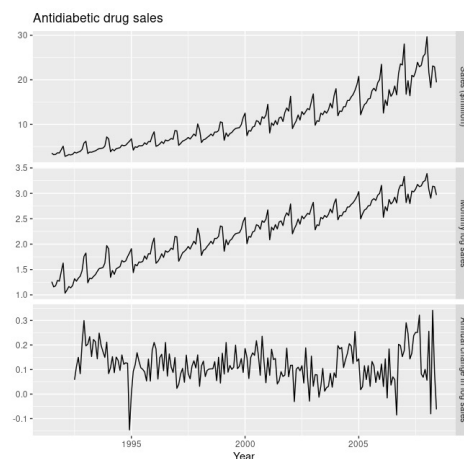
■ Tendencia

- Se puede detectar derivando la serie y viendo que la ACF se convierte en una función que es 1 en desplazamiento 0, y 0 en el resto

■ Periodicidad

- Mediante la autocorrelación (un pico en la autocorrelación en un desplazamiento determinado)

□ Segundo, eliminar estacionalidad y tendencia



<https://otexts.com/fpp2/stationarity.html>

Metodología Box-Jenkins

- Tercero: determinar el tipo de modelo estacionario sobre la señal resultante con ACF


ACF	Modelo
Caída exponencial según aumenta el desplazamiento	AR
Caída alternativa (positiva, negativa) según aumenta el desplazamiento , o senoide amortiguada	AR
Hay uno o dos picos en desplazamientos dif. de cero, resto cero	MA
Caída según aumenta el desplazamiento empezando tras un cierto desplazamiento inicial	ARMA
Todos los valores cero salvo pico en desplazamiento cero	Ruido blanco
Valores altos a intervalos fijos	Componente estacional
No hay caída a cero	Serie no estacionaria

- PACF se usa para elegir el valor de p
 - Último pico importante en PACF es con desplazamiento p
- ACF se usa para elegir el valor de q
 - Último pico importante en ACF es con desplazamiento q

[Box08]

Metodología Box-Jenkins


- Ajuste de los parámetros del modelo
 - Métodos basados en minimizar el error cuadrático medio entre la serie estimada y la serie a estimar
 - Varias metodologías
 - Modelo AR: Ecuaciones de Yule-Walker
 - Similar al método Durbin, o Levison-Durbin
 - Máxima verosimilitud
 - ...



[Box08]

Metodología Box-Jenkins

- Ajuste del modelo
 - Recordemos: modelo probabilístico
 - Error: gaussiana estándar
 - Métodos de bondad de ajuste probabilístico
 - Aikake Information Criterion
 - Bayesian Information Criterion
 - ...
 - Buena bondad de ajuste con modelos gaussianos
 - Fácil de calcular



[Box08]




Metodología Box-Jenkins

- Predicción
 - Utilizando el modelo de filtro lineal a partir de valores anteriores

$$z_{t+l} = \varphi_1 z_{t+l-1} + \dots + \varphi_{p+d} z_{t+l-p-d} - \theta_1 a_{t+l-1} - \dots - \theta_q a_{t+l-q} + a_{t+l}$$
 - O de los "shocks", resolviendo: $\varphi(B)(1 + \psi_1 B + \psi_2 B^2 + \dots) = \theta(B)$

$$z_{t+l} = \sum_{j=0}^{\infty} \psi_j a_{t+l-j}$$
 - Intervalos gaussianos de credibilidad

[Box08]




Variables Exógenas: ARMAX, ARIMAX, SARIMAX

21

Variables Exógenas

- No forman parte de la serie bajo análisis
 - Pero influyen en la misma
 - Es decir, son dependientes de la misma
- Ejemplo
 - Un activo varía
 - A la vez que otro activo varía
 - O a la vez que otro evento externo varía
 - Estación del año
 - Geopolítica
 - Demografía...



<https://machinelearningmastery.com/decompose-time-series-data-trend-seasonality/>

22

Variables Exógenas

- Se añaden al modelo como variables adicionales de entrada
 - Se modelan con coeficientes pasados como en AR y MA
 - Ejemplo, ARMAX:

$$\tilde{z}_t = \phi_1 \tilde{z}_{t-1} + \phi_p \tilde{z}_{t-p} + a_t - \theta_1 a_{t-1} - \theta_q a_{t-q} - \beta_1 e_{t-1} - \beta_r e_{t-r}$$

$$\phi(B)\tilde{z}_t = \phi(B)a_t + \beta(B)e_t$$

- A partir de ahí, si se conoce la serie “exógena”, los procedimientos siguiendo la metodología Box-Jenkins son similares (con alguna diferencia)
- Posibles modelos:
 - ARX
 - MAX
 - ARMAX
 - ARIMAX
 - SARIMAX

Series Temporales Multivariadas

Series Temporales Multivariadas

- Metodología similar (modelo de filtro lineal)
- Pero considerando la extensión multivariante...
 - Los escalares (valor de la serie en tiempo t) son vectores, no escalares
 - Todos los valores de la serie en t van en un mismo vector
 - Los coeficientes son matrices
 - No solo contemplan multiplicar un valor de cada serie en tiempo pasado " $t-l$ "
 - Sino además la relación de unas series en el instante $t-l$ con otras series en el instante t
 - Es decir, una serie en $t-l$ puede influir en otra serie diferente en t
- Las herramientas se complican por la generalización al caso multivariante
 - Cálculo vectorial y matricial
 - Tiene en cuenta a la covarianza entre las series

Referencias Bibliográficas

- [Box08] George E. P. Box, Gwilym M Jenkins and Gregory C Reinsel. "Time series analysis : forecasting and control, 4th ed.". John Wiley and Sons, 2008.